

PROJET FONSECA-FOURMOND

Introduction :

Cette semaine, nous avons mis sur papier les idées auxquelles on pensait et notre plan pour les mettre en oeuvre et les tester.

Structure :

Fonction main

En plus de lancer notre algorithme, la fonction main sert à récupérer les données de notre base. Certaines colonnes, notamment celles des adresse IP sont composées de lettres. Il faut donc encoder les adresses afin de les traiter plus facilement. On utilise pour ça l'objet `LabelEncoder()` de la librairie `sklearn`.

Faut-il mélanger les données ?

Argument contre : chaque enchaînement de message risque d'être perdu

Argument pour : Les anomalies et les messages normaux se suivront

Un quart de notre base donnée sert à l'entraînement et les trois autres aux tests. On vérifie (pas encore) qu'on ne surentraîne pas le modèle, qu'il n'apprend pas par coeur les anomalies. Cela serait contre productif.

Fonction du réseau de neurones

La **fonction d'initialisation** donne le nombre de poids à entraîner et la valeur du biais. En effet, nous choisissons des combinaisons de flags (attribut de la bdd) à donner des fonctions décrites ci-dessous. Elles les évaluent selon nos critères pour obtenir leur taux d'anormalité. Pour cela, nous prenons le résultat du calcul associé à la fonction et le comparons avec la moyenne de tous les résultats qu'on a eu précédemment. Plus le résultat s'éloigne de la moyenne sur un intervalle établi, plus notre taux d'anomalie est grand. On recalcule la moyenne à chaque ligne de donnée, si celle-ci ne relève pas d'une anomalie labellisée.

Cet intervalle s'ajuste au fur et à mesure pour correspondre uniquement aux valeurs labellisées anormales.

Ce taux d'anomalie est donné comme input à notre réseau de neurone.

Notre fonction de valuation est sigmoïde et nous permet de mesurer à si les différents taux combinés dépassent un certain seuil.

Notre bias est initialisé aléatoirement.

La fonction **model**

La fonction **log_loss**

La fonction **gradient**

La fonction **update**

Fonctions de calculs

La première fonction **ratio** donne le résultat de la division de la durée d'un échange sur le nombre de paquets envoyé par la source. Plus le résultat est petit, plus le nombre de paquets en un espace temps est important, ce pattern ressemble à un comportement anormal. de si beaucoup de paquets ont été envoyés en peu de temps.

Notre deuxième fonction demande seulement l'adresse IP, et nous donne si elle a déjà été rencontrée. Si elle ne l'était pas et que la ligne est labellisée normal, nous l'ajoutons au tableau concerné.

Nous avons développé un algorithme de fréquence conditionnel.

Phase de tests

Nous avons les trois quart de notre base de données qui servent aux tests. Notre modèle continue d'évoluer pendant la phase de test. En effet, dès qu'on rencontre du flux que notre algorithme déclare comme normal alors nous mettons à jour nos moyennes et nos pondérations.